

Detección de *clickbait* en noticias

Proyecto Procesado de Lenguaje Natural

Máster en Ciencia de Datos

Universitat de València

Juan Alcaráz Otón, Xueyao An, Fabián Calvo Castillo, Adrián Carrasco Alcalá, Javier Herrero Pérez, Mario Martínez Guillén y Clara Montalvá Barcenilla

Curso 2025/2026

1. Introducción

El periodismo digital ha transformado profundamente la forma en que los usuarios consumen información, generando un ecosistema altamente competitivo donde la atención del lector es el principal activo. En este contexto, ha proliferado el uso del *clickbait*, definido como una estrategia utilizada en los medios digitales que busca llamar la atención a través de los titulares, apelando a las emociones y a la curiosidad de los lectores para forzar el click en la noticia, a menudo en perjuicio de la calidad informativa ([Bravo Araujo et al., 2021](#)).

De acuerdo con [Bazaco et al., 2019](#), se trata de un fenómeno comunicativo dinámico que prioriza la expectativa sobre la información, omitiendo datos clave para generar un vacío de curiosidad o empleando un enfoque sensacionalista. Dentro del marco de este proyecto, se adoptará una perspectiva dual para la definición e identificación de *clickbait*:

- Por un lado, como un titular sensacionalista diseñado con estructuras lingüísticas concretas para captar la atención e incentivar el click, lo cual puede ser detectado analizando únicamente el titular de la noticia.
- Por otro lado, como un titular llamativo que presenta una diferencia considerable con el contenido de la noticia, ya sea porque plantea una pregunta que nunca se responde o porque presenta información completa o parcialmente opuesta a la que se desarrolla en el cuerpo del artículo.

Para automatizar la detección de estos patrones, se empleará el modelo `taniwasl/clickbait_es`, alojado en Hugging Face. Este clasificador se fundamenta en BETO, la versión entrenada para el idioma español del modelo de lenguaje BERT (Bidirectional Encoder Representations from Transformers), ajustado (fine-tuned) específicamente con un corpus aproximado de 30.000 noticias provenientes de múltiples medios españoles. Su funcionamiento radica en procesar la secuencia de palabras del titular analizando el contexto bidireccional de cada término mediante mecanismos de atención. Al haber aprendido de decenas de miles de ejemplos, el modelo es capaz de ponderar características semánticas y sintácticas intrínsecas del *clickbait*, permitiendo predecir y clasificar nuevos titulares con precisión.

2. Objetivo

Objetivo general:

- Analizar y clasificar el uso de técnicas de *clickbait* en la prensa digital española mediante la extracción automatizada de noticias y la aplicación de técnicas de Procesamiento de Lenguaje Natural.

Objetivos específicos:

- Implementar técnicas de web scraping para adquirir de forma automatizada noticias de las categorías Internacional, Nacional y Cultura procedentes de una selección de los principales periódicos y medios de comunicación españoles.
- Analizar los titulares y los contenidos textuales de las noticias desde la perspectiva del NLP para extraer características distintivas que permitan diferenciar las noticias con y sin *clickbait*, evaluando las tendencias en función del medio y la categoría. Adicionalmente, realizar un análisis similar con los títulos y contenidos de videos de YouTube sobre las temáticas 11s, cambio climático y Covid clasificados como fake new y no fake new.

- Integrar un agente de Inteligencia Artificial que automatice la obtención de las noticias y la inferencia y el etiquetado masivo de los titulares, clasificándolos como clickbait o no clickbait. Añadir al agente la capacidad de generar un titular adecuado y no sensacionalista para las noticias clasificadas como clickbait.

3. Metodología

3.1. Adquisición de los datos

De forma previa a la extracción de datos, se revisaron los archivos robots.txt de todos los periódicos digitales seleccionados, verificando que las políticas de acceso de cada medio permitían la recopilación automatizada de las secciones de interés.

Para la recopilación de los datos, se empleó una metodología híbrida: extracción desde las páginas de feed en los periódicos que ofrecían esta opción y scraping directo del código HTML de las páginas web de los que no. Además, se implementaron retardos automatizados entre las descargas para evitar bloqueos de las direcciones IP.

Con todo esto, se obtuvieron noticias de los siguientes periódicos y medios españoles:

- ABC
- elDiario
- El Confidencial
- La Vanguardia
- 20minutos
- OkDiario
- RTVE
- Mediterráneo Digital
- El HuffPost

En particular, los periódicos digitales *Mediterráneo Digital* y *El HuffPost* destacan por su gran cantidad de titulares sensacionalistas y que no se corresponden con el contenido de los cuerpos de las noticias.

Se extrajeron artículos de las siguientes categorías:

- Internacional: Noticias de ámbito mundial.
- Nacional: Noticias de España y de sus regiones.
- Cultura: Artes, cine, literatura, entretenimiento, etc.

Las noticias extraídas se almacenaron en formato JSON con la siguiente estructura:

```
{
  "Link": "string",
  "Periódico": "string",
  "Fecha": "string (YYYY-MM-DD)",
  "Título": "string",
  "Subtítulo": "string o null",
  "Categoría": "string",
  "Contenido": "string"
}
```

Los campos de esta estructura representan lo siguiente:

Campo	Tipo	Descripción
Link	string	URL del artículo original
Periódico	string	Nombre del medio de comunicación
Fecha	string	Fecha de publicación de la noticia (formato YYYY-MM-DD)
Título	string	Título principal del artículo
Subtítulo	string o null	Subtítulo o descripción breve
Categoría	string	Categoría o sección del artículo
Contenido	string	Cuerpo de la noticia

Se generó un JSON para cada periódico en el que se recogían todas sus noticias. Estos ficheros fueron guardados en la carpeta 'data/' con el formato 'nombredelmedio.json'.

3.2. Preprocesado del texto

Una vez obtenidas suficientes noticias de todos los medios en sus respectivos JSON, se creó el archivo JSON común 'conjunto_noticias.json' con todas ellas.

Tras un análisis del contenido almacenado en dicho archivo, se determinó que los elementos del texto que debían eliminarse eran los siguientes:

- Comillas: /"/, «», ", "" y algunas más.
- Signos de interrogación y exclamación: ¡! ¿?
- Guiones: --
- URLs
- Direcciones de correo y cuentas de twitter: empiezan por @
- Saltos de línea: \n \r
- Signos de puntuación: , ; : .
- Corchetes y paréntesis: [] ()
- Emojis

3.3. Clasificación de las noticias en clickbait/no clickbait

Una vez finalizado el preprocesado del texto y consolidado el conjunto de datos limpio en 'conjunto_noticias_limpio.json', se procedió a la etapa de clasificación automática de los titulares. Para esta tarea central, se implementó el modelo preentrenado taniwasl/clickbait_es, disponible en el [repositorio de Hugging Face](#).

El procedimiento técnico de clasificación consta de los siguientes pasos:

1. Carga del entorno de inferencia: A través de la librería `transformers`, se instancia tanto el tokenizador correspondiente a la arquitectura BETO como el propio modelo de clasificación de secuencias (`AutoModelForSequenceClassification`).
2. Tokenización de titulares: Cada valor del campo "Título" de nuestro JSON se pasa por el tokenizador. Este paso convierte el texto crudo en tensores y añade los tokens especiales de inicio y final de oración que requiere la red neuronal para acotar el contexto.
3. Inferencia del modelo: Los tensores se introducen en el modelo preentrenado, el cual hace pasar las representaciones vectoriales por sus distintas capas ocultas. Gracias a su fine-tuning previo sobre noticias de la prensa española, el sistema es capaz de detectar patrones típicos del sensacionalismo en español como el uso de hipérbolas, deícticos temporales o preguntas abiertas.
4. Etiquetado: La red neuronal devuelve unos valores que determinan la probabilidad de que el texto pertenezca a la clase clickbait o a la clase no clickbait. A cada noticia en el conjunto de datos se le adjunta tanto una etiqueta de clickbait/no clickbait como la probabilidad de la misma devuelta por el modelo.

La automatización de este proceso nos permitió generar la variable objetivo para todo el conjunto de noticias. Este etiquetado de los datos posibilita realizar un análisis cruzado para validar estadísticamente qué medios y categorías temáticas incurren con mayor frecuencia en la desinformación o en tácticas de clickbait.

3.4. Extracción de características

3.4.1. Enfoque inicial: características lingüísticas

Se inició el análisis calculando la distancia coseno entre los embeddings del título y los fragmentos del cuerpo de cada noticia. Con este enfoque se buscaba capturar la relación semántica entre el titular y el contenido, bajo la hipótesis de que los artículos con clickbait presentarían mayores discrepancias semánticas entre ambos elementos. Siguiendo esta misma línea de razonamiento, se intentaron aplicar técnicas de topic modeling para evaluar si existía también una disonancia a nivel temático que ayudara a identificar estos casos.

Se exploraron variables lingüísticas más sofisticadas, incluyendo deícticos, intensificadores, superlativos, palabras emocionales y frases de curiosidad. Estas características fueron seleccionadas por su relevancia teórica en la detección de clickbait, al ser indicadores habituales en titulares sensacionalistas.

No obstante, no se consiguieron obtener resultados estadísticamente significativos que permitieran diferenciar los grupos (clickbait y no clickbait).

3.4.2. Exploración de características alternativas

Se evaluaron diferentes enfoques con el objetivo de mejorar la capacidad discriminativa del modelo:

- Análisis de entropía: Se calculó la entropía como medida de redundancia léxica, buscando patrones en la repetición de palabras entre títulos y contenido.
- Análisis de sentimientos: Se aplicaron métodos de análisis de sentimiento basados en BERT, bajo la hipótesis de que el clickbait podría presentar patrones emocionales diferenciados.
- Otras métricas: Se exploraron índices de legibilidad (Flesch-Kincaid), longitud de textos y métodos de pregunta-respuesta.

Ninguna de estas características logró producir diferencias estadísticas significativas entre los grupos, lo que motivó la transición hacia un enfoque basado en representaciones neuronales.

3.5. Fine-tuning con BERT

Ante los resultados limitados del enfoque basado en características manuales, se recurrió al fine-tuning de un modelo de transformers. Se utilizó **bert-base-multilingual-cased** como modelo base, optimizado para el procesamiento de texto en múltiples idiomas, incluyendo el español. Con la perspectiva de este modelo, se aprenden las representaciones contextuales de los textos directamente de los datos, capturando patrones semánticos que son difíciles de formalizar utilizando métricas.

La configuración del entrenamiento fue la siguiente: 3-4 épocas, según el modelo; learning rate de $2 \cdot 10^{-5}$, optimizador Adam, división de datos 80% entrenamiento y 20% validación; tamaño de batch de 16 para títulos y 8 para contenido; corrección de desbalance mediante pesos de clase inversamente proporcionales a la frecuencia; y un dropout de 0.2 para evitar sobreajuste.

Se entrenó el modelo durante tan pocas épocas para evitar modificar demasiado los pesos del modelo preentrenado, dado el tamaño limitado del corpus. El objetivo era que el modelo aprendiera patrones específicos de clickbait sin perder la estructura semántica general de las representaciones de BERT.

Se realizó el fine-tuning de forma independiente para títulos y contenido, con longitudes máximas de secuencia de 128 y 512 tokens, respectivamente. Los embeddings de clasificación fueron extraídos del token *[CLS]*.

Se tuvo en cuenta que BERT fue preentrenado sobre texto crudo y completo, incluyendo stopwords y formas flexionadas de las palabras, por lo que su arquitectura de atención está optimizada para procesar este tipo de entrada. Lematizar o eliminar palabras alteraría la estructura sintáctica y semántica que BERT aprendió a interpretar. Palabras como "corriendo" y "correr" tienen representaciones internas distintas que el modelo utiliza intencionalmente para capturar matices de significado. Además, los stopwords no son simplemente ruido, palabras como "pero", "aunque" o "sin embargo" pueden ser indicadores lingüísticos importantes de estructura argumentativa y emotional framing, rasgos relevantes para la detección de clickbait. Es por esta razón que se decidió no lematizar ni eliminar las stopwords.

3.6 Modelo base para vídeos de YouTube

Se decidió realizar un análisis adicional sobre un conjunto de vídeos de YouTube sobre las temáticas 11s, cambio climático y Covid clasificados como fake news y no fake news. Estos datos fueron obtenidos del siguiente [repositorio de GitHub](#).

Como parte de este análisis, se optó por utilizar *distilbert-base-uncased* como modelo de extracción de representaciones semánticas. Este modelo es una versión destilada de BERT optimizada para textos en inglés, idioma en el que se encuentran los vídeos scrapeados, lo que lo hace más adecuado que *bert-base-multilingual-cased* para este caso concreto.

A diferencia del análisis principal realizado con las noticias en español, en este caso no fue posible llevar a cabo un proceso de fine-tuning del modelo. La razón principal es el tamaño del corpus disponible, ya que el conjunto de vídeos de YouTube cuenta únicamente con 147 registros, distribuidos entre las tres temáticas, frente a los 540 ejemplos utilizados en el análisis principal de las noticias. Con un volumen tan reducido de datos, el fine-tuning supervisado de un modelo transformer deriva en sobreajuste, por lo que los embeddings resultantes no reflejarían la estructura semántica real.

Por ello, se utilizó el modelo base directamente como extractor de características, sin ningún tipo de ajuste supervisado. De esta forma, los embeddings extraídos a partir del token *[CLS]* capturaron la semántica general del texto tal y como la codificó el modelo preentrenado, sin estar sesgados hacia la tarea de clasificación de fake news. El resto del pipeline (reducción dimensional con UMAP y visualización) se mantuvo idéntico al análisis principal.

3.7. Validación estadística

Para validar la significancia estadística de la separación observada, se aplicó la **prueba U de Mann-Whitney**, un test no paramétrico que contrasta si dos distribuciones independientes son estadísticamente diferentes. Se calculó el *p*-valor para ambas dimensiones UMAP de forma independiente, aplicando corrección de Bonferroni para comparaciones múltiples.

3.8. Implementación Agéntica

Dentro del sistema desarrollado se integró un agente de inteligencia artificial encargado de automatizar el análisis de las noticias extraídas y clasificarlas en función de la presencia o ausencia de clickbait. Para ello, se desarrolló una aplicación en Streamlit que combina técnicas de scraping web, lectura de feeds RSS y procesamiento de lenguaje natural mediante un modelo LLM de OpenAI, GPT-OSS-120b, integrado con LangChain.

En primer lugar, la aplicación obtiene las noticias de los distintos medios digitales españoles ya mencionados en la sección 3.1, reutilizando las mismas técnicas de scraping para cada uno. Es decir, dependiendo del periódico, la extracción se realiza a partir de feeds RSS o mediante scraping directo del HTML, y de cada noticia se recopilan campos como el enlace original, el periódico, la fecha, el título, el subtítulo, la categoría y el contenido del artículo.

Una vez extraídas, las noticias se incorporan a una cola de pendientes y son analizadas por el agente. El modelo evalúa principalmente la relación entre el titular y el contenido para detectar rasgos habituales del clickbait, como exageración, ambigüedad, suspense artificial, carga emocional excesiva o desajuste entre lo prometido por el titular y la información real del texto. Como resultado, cada noticia se clasifica como *clickbait* o *no clickbait*, acompañada de un score de confianza y una breve explicación del criterio utilizado.

Los resultados se almacenan en archivos JSON separados por medio, evitando duplicados y conservando el progreso de cada ejecución. Además, cuando una noticia es clasificada como clickbait, el agente propone un titular alternativo más neutro, informativo y fiel al contenido original. La aplicación también genera logs de seguimiento y mantiene una carpeta de noticias pendientes para conservar aquellas que no hayan podido procesarse correctamente y permitir su análisis posterior.

4. Resultados

4.1. Extracción de características

A partir de la distancia coseno entre el título y los párrafos del contenido, combinada con las diferencias lingüísticas descritas anteriormente, se entrenó un clasificador mediante regresión logística. Otros clasificadores más complejos mostraron sobreajuste, por lo que se optó por este modelo más simple.




Figura 1. Espacio embebido UMAP que relaciona el título con el cuerpo de la noticia.




Figura 2. Curva ROC del clasificador basado en características lingüísticas.

En la Figura 1, en la que el número encima de cada punto corresponde al párrafo del cuerpo, se observa que las noticias con mayor similitud coseno entre título y contenido tienden a agruparse en regiones próximas del espacio embebido. Sin embargo, como refleja la Figura 2, la capacidad discriminativa del clasificador resultante es limitada (AUC = 0.660), lo que evidencia que las características lingüísticas manuales no son suficientes para una detección robusta del clickbait. Se ha validado a partir de la clasificación de Taniwa, hacerlo con GPT sería una futura implementación.

4.2. Modelo Taniwa

4.2.1. Embedding tras fine-tuning

Tras el fine-tuning con las etiquetas del sistema Taniwa, los embeddings resultantes muestran una separación clara entre ambas clases. La siguiente figura revela clusters bien definidos de clickbait y no-clickbait, tanto para títulos como para contenido.




Figura 3. Representación UMAP de los embeddings tras fine-tuning para títulos (Taniwa).




Figura 4. Representación UMAP de los embeddings tras fine-tuning para contenido (Taniwa).

La separación visual observada fue validada mediante la prueba U de Mann-Whitney, que confirmó significancia estadística ($p \ll 0.05$) en ambas dimensiones UMAP. Cabe recordar que esta separación es en parte consecuencia del fine-tuning supervisado: el modelo optimiza sus representaciones para discriminar las etiquetas de entrenamiento, por lo que la separación en el espacio embebido no implica necesariamente que el clickbait sea intrínsecamente distinguible a nivel lingüístico.

4.2.2. Variación por categoría temática




Figura 5. Representación UMAP de títulos segmentada por categoría temática (Taniwa).




Figura 6. Representación UMAP de contenido segmentada por categoría temática (Taniwa).

La Figura 5 presenta los espacios embebidos segmentados por categoría temática, usando las etiquetas de Taniwa. La categoría *Cultura* presenta una mayor propensión hacia el clickbait, evidenciada por su concentración en la región del espacio UMAP asociada a esta etiqueta. Las categorías *Internacional* y *Nacional* muestran una distribución más equilibrada entre ambas clases.

4.2.3. Variación por medio de comunicación




Figura 7. Representación UMAP de títulos segmentada por medio de comunicación (Taniwa).




Figura 8. Representación UMAP de contenido segmentada por medio de comunicación (Taniwa).

La Figura 7 presenta la distribución segmentada por medio de comunicación. Los resultados no evidencian que ningún periódico concentre sus contenidos de forma sistemática en una sola clase. Los periódicos analizados presentan distribuciones heterogéneas en ambas regiones del espacio, sin que exista un medio que muestre una preferencia marcada hacia el clickbait.

4.3. Modelo GPT

4.3.1. Embeddings tras fine-tuning con etiquetas del agente GPT

Se repitió el análisis utilizando las etiquetas generadas por el agente GPT, que clasifica las noticias teniendo en cuenta tanto el título como el contenido.




Figura 9. Representación UMAP de los embeddings tras fine-tuning para títulos (GPT).




Figura 10. Representación UMAP de los embeddings tras fine-tuning para contenido (GPT).

La Figura 9 muestra los resultados obtenidos. Al igual que con las etiquetas de Taniwa, se observa una separación clara entre ambas clases en el espacio UMAP, validada estadísticamente con la prueba U de Mann-Whitney ($p \ll 0.05$).

4.3.2. Variación por categoría temática (GPT)




Figura 11. Representación UMAP de títulos segmentada por categoría temática (GPT).




Figura 12. Representación UMAP de contenido segmentada por categoría temática (GPT).

La Figura 11 muestra la distribución por categoría temática con las etiquetas del agente GPT. Los patrones son coherentes con los observados en el análisis con etiquetas Taniwa: la categoría *Cultura* concentra más contenidos clasificados como clickbait, mientras que *Internacional* y *Nacional* presentan distribuciones más equilibradas.

4.3.3. Variación por medio de comunicación (GPT)




Figura 13. Representación UMAP de títulos segmentada por medio de comunicación (GPT).




Figura 14. Representación UMAP de contenido segmentada por medio de comunicación (GPT).

La Figura 13 presenta la distribución por medio de comunicación con etiquetas GPT. De forma consistente con el análisis anterior, no se observa ningún periódico con una preferencia sistemática hacia el clickbait.

4.4. Modelo para vídeos de YouTube

4.4.1. Embeddings con vídeos de YouTube etiquetados

Como parte del análisis adicional que se realizó sobre el conjunto de datos obtenidos de los vídeos de YouTube, se aplicó el mismo proceso de reducción UMAP sobre los embeddings extraídos, tanto para los títulos como para el contenido de los vídeos, coloreando los puntos según su etiqueta de Fake News o No Fake News.




Figura 15. Representación UMAP de los embeddings de los videos para títulos.




Figura 16. Representación UMAP de los embeddings de los videos para contenido.

Los resultados obtenidos muestran, en ambos casos, una ausencia de separación clara entre ambas clases. En el espacio de embeddings de títulos, los puntos de ambas categorías aparecen distribuidos de forma entremezclada dentro de los mismos clústeres, sin que pueda identificarse ninguna frontera de separación. En el espacio de contenido la situación es aún más homogénea, con ambas clases completamente solapadas en el clúster principal y únicamente un outlier aislado que representa un video con características atípicas respecto al resto del corpus.

Estos resultados son coherentes con las limitantes del análisis. Al no disponer de fine-tuning, el modelo no ha sido guiado para discriminar entre videos con fake news y no fake news, por lo que los embeddings no contienen señal supervisada que permita separar ambas clases. A esto se suma el reducido tamaño del corpus (147 videos), que hace que UMAP no tenga suficiente masa de datos para construir una geometría estable en el espacio reducido.

4.4.2. Variación por categoría temática (YouTube)

Como parte del mismo análisis adicional sobre los videos de YouTube, se exploró la distribución de los embeddings segmentada por categoría temática (11s, Cambio climático y Covid), utilizando las etiquetas Fake News y No Fake News.




Figura 17. Representación UMAP de los títulos de los videos segmentada por categoría temática.




Figura 18. Representación UMAP del contenido de los videos segmentada por categoría temática.

En este caso los resultados presentan una estructura un poco más interpretable que la obtenida con la separación por etiqueta. En el espacio de títulos se aprecian dos regiones diferenciadas dentro del espacio UMAP, en el que los videos de Covid tienden a agruparse en la zona superior-derecha del espacio, mientras que los videos de 11s y Cambio climático coexisten en la región inferior-izquierda, aunque sin una frontera entre ellos. Esta separación parcial es esperable teniendo en cuenta que los títulos de videos sobre Covid incorporan terminología médica que el modelo codifica en regiones distintas del espacio semántico,

mientras que los vídeos sobre el 11s y el cambio climático comparten un lenguaje más genérico de denuncia y conspiración que los aproxima en el espacio embebido.

En el espacio de contenido, la separación por categoría es prácticamente inexistente, con las tres temáticas completamente mezcladas en el clúster principal. Esto sugiere que las descripciones o transcripciones de los vídeos presentan estilos más homogéneos que los títulos, convergiendo hacia un registro común independientemente del tema tratado. En cualquier caso, los resultados de separación por categoría, aunque ligeramente más informativos que los de separación por etiqueta, tampoco alcanzan la claridad observada en el análisis principal.

4.5. Comparación entre títulos y contenido

En ambos sistemas de etiquetado (Taniwa y GPT), el modelo entrenado sobre títulos mostró una convergencia más estable durante el entrenamiento y una discriminación más robusta en la comparación posterior. Este resultado es coherente con la naturaleza del clickbait como fenómeno del titular, el título es el elemento diseñado para generar curiosidad o engañar, mientras que el cuerpo de la noticia tiende a ser más informativo y neutral.

El modelo de contenido presenta mayor inestabilidad en las curvas de entrenamiento, lo que puede atribuirse a la longitud de los textos (hasta 512 tokens), al tamaño reducido del corpus y al truncado que descarta información de las noticias más largas.

Los resultados obtenidos en el análisis adicional de vídeos de YouTube contrastan notablemente con los del análisis principal. Mientras que en el corpus de noticias el fine-tuning permitió obtener embeddings con una separación estadísticamente significativa entre clickbait y no-clickbait tanto en títulos como en contenido, el análisis de YouTube arroja representaciones sin estructura discriminativa clara en ninguna de las dos dimensiones textuales.

4.6. Comparación entre clasificadores: BERT vs. Taniwa

Para evaluar en qué medida el modelo BERT (entrenado con etiquetas GPT) reproduce las decisiones del sistema Taniwa, se realizó una inferencia sobre el corpus de Taniwa y se compararon las clasificaciones mediante el coeficiente Kappa de Cohen, que mide el acuerdo entre dos clasificadores corrigiendo la fracción de coincidencias atribuibles al azar. Es importante recalcar que las noticias de Taniwa y GPT son distintas, por lo que se va hacer inferencia con un conjunto de noticias que GPT nunca ha visto.

Con el objetivo de evitar el sobreajuste durante el entrenamiento con etiquetas GPT, se utilizaron únicamente 4 épocas tanto para el modelo de título como para el de contenido, junto con un *learning rate* de $3 \cdot 10^{-5}$. Las curvas de entrenamiento confirmaron una convergencia estable y sin sobreajuste. Para el título, el error de entrenamiento descendió de 0.68 a 0.62 y el de validación de 0.68 a 0.63; para el contenido, el error de entrenamiento pasó de 0.69 a 0.64 y el de validación de 0.69 a 0.62.




Figura 19. Comparación entre BERT y Taniwa para títulos.




Figura 20. Comparación entre BERT y Taniwa para contenido.

Los resultados se resumen en la siguiente tabla, donde el acuerdo simple se ha calculado como la suma de ambos aciertos.

Métrica	Títulos	Contenido
Acuerdo simple	82.0%	62.6%
Cohen's Kappa	0.437	-0.023

Métrica	Títulos	Contenido
Interpretación	Moderado	Bajo

Tabla 1. Acuerdo entre BERT (entrenado con GPT) y Taniwa.

Las representaciones de la figura anterior permiten analizar visualmente la distribución espacial de los acuerdos y desacuerdos. En el caso de los títulos, se aprecia una zona de mayor densidad (verde) donde ambos modelos coinciden en la detección de clickbait, lo que lleva a pensar que existe una señal semántica común en los titulares. En cambio, para el contenido no se observan distribuciones espaciales claras, lo que indica que la coincidencia entre modelos es menos clara.

Esta asimetría entre título y contenido puede explicarse por las diferencias en los datos de entrenamiento de cada clasificador: Taniwa fue entrenado únicamente sobre títulos, por lo que sus representaciones capturan señales propias de los titulares. El modelo BERT, entrenado con las etiquetas de GPT que considera tanto el título como el cuerpo, incorpora información adicional del contenido que Taniwa no ha procesado. Por lo tanto, el criterio entre ambos es más efectiva cuando se evalúa el título, y empeora al analizar el cuerpo de la noticia.

En cuanto a las discrepancias por medio de comunicación:

Periódico	Título	Contenido
El Confidencial	35.0%	50.0%
RTVE	25.0%	43.3%
ABC	18.3%	28.3%
okdiario	16.7%	38.3%
La Vanguardia	15.0%	25.0%
ElDiario	15.0%	35.0%
20minutos	15.0%	30.0%
Huffingtonpost	13.3%	45.0%
Mediterráneo Digital	8.3%	41.7%

El Confidencial concentra el mayor porcentaje de desacuerdos tanto en título como en contenido. Otro resultado interesante es que ambos modelos discrepan poco (observando el título) con el Mediterráneo Digital y Huffingtonpost que son los periódicos que estaban buscados con mayor clickbait.

Por categoría, la discrepancia es la siguiente:

Categoría	Título	Contenido
Cultura	33.8%	43.8%
Internacional	12.1%	44.7%
Nacional	10.5%	24.7%

Estos patrones son coherentes con las diferencias de criterio entre ambos sistemas. Taniwa tiende a clasificar como clickbait las noticias de Cultura por sus títulos llamativos, mientras que GPT, al revisar el contenido, no las identifica como clickbait. Por el contrario, GPT clasifica una proporción mayor de noticias de Internacional (aunque muy cerca está cultura) como clickbait al analizar el cuerpo, lo que Taniwa no puede detectar al trabajar solamente con el titular. Estas discrepancias reflejan, por tanto, no solo las limitaciones de cada modelo, sino también la diferencia conceptual entre ambas aproximaciones al clickbait.

Un Kappa de 0.41 indica un acuerdo moderado, lo que refleja que ambos clasificadores comparten el criterio de detección de forma parcial pero no completa. Esta divergencia es esperable: GPT razona de forma holística sobre el texto completo, mientras que BERT aprende patrones estadísticos locales a partir de un corpus limitado. El acuerdo moderado obtenido en títulos sugiere que ambos sistemas capturan señales similares en los titulares, mientras que el acuerdo bajo en contenido evidencia que el cuerpo de la noticia no contiene una señal de clickbait igualmente accesible para ambos enfoques.

Por último, se han seleccionado algunos ejemplos representativos de casos de desacuerdo entre BERT-GPT y Taniwa. Solo se van a comprar los títulos ya que estos han sido los únicos capaces de separar.

Ejemplo 1: Titular sensacionalista que solo Taniwa identifica

- Título: "Rosalía canta malamente y explica por qué ya no interpreta el mal querer tras leer la pancarta crítica de un fan"

- Periódico: 20minutos
- Categoría: Cultura
- Taniwa: Clickbait | BERT: No Clickbait (score: 0.456)

En este caso Taniwa lo detectó como Clickbait mientras que Bert-GPT no. Se observa que el título tiene palabras sensacionalistas como "malamente" que Taniwa ha podido identificar como clickbait.

Ejemplo 2: Noticia que solo BERT detecta clickbait

- Título: "Amine Kessaci: la narcocracia crece en los lugares que el Estado ha dejado abandonados"
- Periódico: ABC
- Categoría: Internacional
- Taniwa: No Clickbait | BERT: Clickbait (score: 0.551)

A pesar del tono informativo, la colocación de un personaje como protagonista del titular y el uso de estructuras más emotivas es un patrón que BERT asocia con clickbait basándose en su entrenamiento con GPT.

Ejemplo 3: Noticia claramente clasificada como No Clickbait

- Título: "Tiroteo en el centro de Atenas: un hombre de 89 años deja cinco heridos y es detenido tras darse a la fuga"
- Periódico: 20minutos
- Categoría: Internacional
- Ambos: No Clickbait (score BERT: 0.223)

Titular directo, informativo y sin elementos sensacionalistas.

Ejemplo 4: Noticia claramente identificada como Clickbait

- Título: "El Rey Carlos III trolea al presidente Trump en un brindis en la Casa Blanca: si no fuera por nosotros ustedes hablarían francés"
- Periódico: 20minutos
- Categoría: Internacional
- Ambos: Clickbait (score BERT: 0.616)

Uso explícito de palabras emotivas ("trolea"). Ambos modelos reconocen este patrón consistentemente.

5. Conclusiones

Analizando los resultados, se observó que la extracción de características para detectar clickbait no devolvía resultados concluyentes. A pesar de utilizar diferentes métricas y algoritmos, las dos únicas variables destacables para el clasificador acababan siendo la similitud del coseno y la diferencia lingüística, ambas entre el título y el cuerpo, obteniendo como resultado un área bajo la curva de 0.660. No obstante, esta comparación solo fue realizada con las etiquetas de Taniwa (en un análisis futuro se podría realizar una comparación con las etiquetas del modelo de OpenAI).

En vista de estos resultados, se decidió cambiar la perspectiva y realizar un fine-tuning en el modelo de BERT, con el objetivo de destilar los modelos de GPT y Taniwa. Para este caso, sí se consiguieron separar o diferenciar los datos según su clase, aunque los resultados no son comparables con los de la extracción de características, ya que esto se utilizó un aprendizaje supervisado (en base a las etiquetas clasificadas previamente).

Por lo que respecta a los resultados obtenidos, el modelo de Taniwa detectaba como clickbait las noticias de Cultura, independientemente del medio. Lo interesante es que consiguió separar tanto el cuerpo como el título de una manera clara, a pesar de que Taniwa solo clasificaba por títulos. No obstante, entre Nacional e Internacional resultó más difícil separar las distribuciones. Para el tipo de periódico, no se encontraron distribuciones separadas.

En cuanto al modelo GPT, su definición de clickbait fue diferente, comparando el cuerpo con el título de la noticia. Se observó que la categoría con menor densidad de clickbait era Cultura, mientras que la que más tenía era Internacional. Este resultado se puede deber a que, aunque los titulares de Cultura suelen ser más emotivos, el título y el contenido no se desvían mucho. Con los medios de comunicación se obtuvieron resultados similares.

Para los vídeos de YouTube, a pesar de que podía resultar esperable encontrar un mayor uso del clickbait (o fake news), al no tratarse de noticias de medios serios y con reputación, los resultados no fueron estadísticamente significativos. Tal vez con un conjunto de datos mayor se podría haber realizado un entrenamiento supervisado del modelo y haber llegado a mejores conclusiones.

Con el objetivo de comparar ambos modelos, se entrenó el modelo de GPT con el embedding de BERT y haciendo inferencia con los datos de Taniwa para ver qué noticias clasificaba como clickbait y no clickbait. Los resultados obtenidos muestran que

para el título sí es capaz de coincidir en las noticias clickbait, concentrando estos valores de coincidencia en una región aislada del UMAP. Sin embargo, para el cuerpo no es capaz de identificarlo bien, posiblemente debido a que Taniwa solo clasifica por el título.

Una posible vía para un análisis futuro sería realizar el fine-tuning por medios de comunicación, de manera que se pudiera ver qué medios de comunicación tienen formas semánticas diferentes y se pudiera hacer inferencia.

6. Bibliografía

1. Bravo Araujo, A., Serrano-Puche, J., y Novoa Jaso, M. (2021). Uso del clickbait en los medios nativos digitales españoles. Un análisis de El Confidencial, El Español, Eldiario.es y Ok Diario. Doxa Comunicación. Revista Interdisciplinar de Estudios de Comunicación y Ciencias Sociales, (32), 185-210.
2. Bazaco, A., Redondo, M., y Sánchez-García, P. (2019). El clickbait como estrategia del periodismo viral: concepto y metodología. Revista Latina de Comunicación Social, (74), 94-115.
3. Taniwa (2023). taniwasl/clickbait_es. Hugging Face. Disponible en: https://huggingface.co/taniwasl/clickbait_es
4. Devlin, J., Chang, M.-W., Lee, K., y Toutanova, K. (2018). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. CoRR, abs/1810.04805. Disponible en: <http://arxiv.org/abs/1810.04805>
5. Mann, H. B., y Whitney, D. R. (1947). *On a Test of Whether one of Two Random Variables is Stochastically Larger than the Other*. The Annals of Mathematical Statistics, 18(1), 50–60. Disponible en: <https://doi.org/10.1214/aoms/1177730491>
6. jopebrui. (2026). fake-news-detector [Videos de YouTube con títulos, transcripción y puntuación de Fake New]. GitHub. Disponible en: <https://github.com/jopebrui/fake-news-detector>
7. Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1), 37–46. Disponible en: <https://doi.org/10.1177/001316446002000104>
8. Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, 33(1), 159–174. Disponible en: <https://doi.org/10.2307/2529310>

7. Repositorio del proyecto

Se puede consultar el repositorio de GitHub del proyecto desde el siguiente enlace: <https://github.com/hepejaAED/ProyectoNLP.git>