

Universitat de València



# **DETECCIÓN DE *CLICKBAIT* EN NOTICIAS**

**Procesamiento de Lenguaje Natural - Máster en Ciencia de Datos**

**Grupo 4**

**Juan Alcaraz, Xueyao An, Fabián Calvo, Adrián Carrasco, Javier Herrero, Mario Martínez, Clara Montalvá**

# Índice

1

INTRODUCCIÓN

2

OBJETIVOS

3

PIPELINE

4

METODOLOGÍA

5

RESULTADOS

6

CONCLUSIONES


# 1. Introducción

## ¿Qué se entiende por *Clickbait*?

Titular sensacionalista diseñado con estructuras lingüísticas concretas para captar la atención e incentivar el click.

Esto puede ser detectado analizando únicamente el titular de la noticia.

Titular llamativo que presenta una diferencia considerable con el contenido de la noticia, ya sea porque plantea una pregunta que nunca se responde o porque presenta información completa o parcialmente opuesta a la que se desarrolla en el cuerpo de la noticia.






## 2. Objetivos

Analizar y clasificar el uso de técnicas de clickbait en la prensa digital española mediante la extracción automatizada de noticias y la aplicación de técnicas de PLN.



### Objetivo 1

Implementar técnicas de web scraping para las categorías de noticias seleccionadas.



### Objetivo 2


Analizar titulares y contenidos de las noticias para extraer características que permitan diferenciar las noticias con y sin clickbait.



### Objetivo 3




Integrar un Agente que automatice la obtención de noticias, su inferencia y el etiquetado de titulares, como clickbait o no clickbait.

### 3. Pipeline





## **4. Metodología**



## 4.1. Adquisición de los Datos

La materia prima para nuestro trabajo eran **noticias de prensa**, principalmente periódicos conocidos del ámbito nacional.

Posteriormente decidimos ampliar la búsqueda y usar **vídeos de YouTube**, con sus transcripciones.



## 4.1.1. Noticias de Prensa



Nuestra fuente principal de datos eran los periódicos. Por desgracia, muchos de los periódicos más conocidos **ponían bastantes dificultades** para extraer noticias:

- Muros de pago (*pay walls*)
- Ausencia de feed RSS
- Bloqueos


Tras una búsqueda **decidimos** **scrapear** los siguientes medios:

1. ABC
2. El Diario
3. El Confidencial
4. La Vanguardia
5. 20 Minutos
6. OK Diario
7. RTVE
8. **HuffingtonPost**
9. **Mediterráneo Digital**

Consiguiendo **más de 500 noticias**. De las secciones de: **Nacional, Internacional y Cultura**



## 4.1.2. Vídeos de YouTube



Tras empezar el trabajo surgió la idea de intentar **extrapolar los resultados a vídeos** de YouTube.

Probamos con diversas librerías para obtener los vídeos con sus transcripciones:

- `youtube_transcript_api`
- `yt_dlp`

Pero **YouTube bloqueaba la IP** a las pocas peticiones. Haciendo imposible un scrapeo eficiente. Optamos por utilizar los datos ya disponibles en un repositorio. Las temáticas de los vídeos son:

**11S, Covid19 y Cambio Climático**

```
---> 96         raise IpBlocked(video_id)
      97     response.raise_for_status()
      98     return response
```

**IpBlocked:**

Could not retrieve a transcript for the video <https://www.youtube.com/watch?v=BXmwHZCAGm4>! This

YouTube is blocking requests from your IP. This usually is due to one of the following reasons:




## 4.2. Procesado del Texto




Los textos extraídos **presentaban bastantes impurezas**, y además requerían de un **procesamiento previo** para poder aplicar los modelos sobre ellos.

Los elementos más importantes a limpiar:

- **Comillas.**
- **Etiquetas HTML.**
- **Signos de exclamación e interrogación.**
- **Signos de puntuación** (según el modelo).
- **Salto de línea:** `\n` y `\r`.
- **Correos y menciones a cuentas de X** (Twitter).
- **Emojis.**
- **URLs.**



## 4.2.1 Lematización y Stopwords



Además de la limpieza de caracteres no deseados que pudieran dificultar el trabajo de los modelos y la extracción de características, también nos enfrentamos a varios disyuntivos:

- Eliminar **Stopwords**: según el modelo algunas palabras consideradas como stopword podían llegar a ser útiles y aportar información.
- **Lematizar** el texto: existen numerosos modelos para los cuales **lematizar el texto es necesario** para obtener buenos resultados, mientras que **para otros resulta contraproducente**, y dificulta su tarea.





## 4.3. Clasificación de las Noticias en Clickbait / No Clickbait

### 1. INSTANCIAR BETO

Instanciamos tokenizador de BETO y el modelo de clasificación Taniwa

### 2. TOKENIZACIÓN TITULARES


El título del JSON se introduce al BETO y extraemos tensores

### 3. INFERENCIA MODELO


Los tensores se introducen al modelo de clasificación

### 4. ETIQUETADO

Se asigna la etiqueta y su probabilidad a cada noticia



## 4.4. Extracción de Características



| ENFOQUE INICIAL:<br>CARACTERÍSTICAS LINGÜÍSTICAS                                                                                                                                | EXPLORACIÓN DE<br>CARACTERÍSTICAS ALTERNATIVAS                                                                                                                                                                                                          |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Comparación entre los embeddings del título y cuerpo de las noticias: <ul style="list-style-type: none"><li>• <b>DISTANCIA COSENO</b></li><li>• <b>TOPIC MODELING</b></li></ul> | <ul style="list-style-type: none"><li>• <b>ANÁLISIS ENTROPÍA:</b> Medida de redundancia léxica.</li><li>• <b>ANÁLISIS SENTIMIENTOS</b></li><li>• <b>OTRAS MÉTRICAS:</b> Índices de legibilidad, longitud textos y métodos pregunta-respuesta.</li></ul> |



Sin resultados estadísticamente significativos

## 4.5. Fine-Tuning con BERT



- **BERT** como modelo base (bert-base-multilingual-cased), que aprende representaciones contextuales de los textos para capturar patrones semánticos.
- Entrenado **3-4 épocas**, para aprender patrones específicos del clickbait sin perder la estructura semántica general del BERT.
- **Fine-tuning independiente para títulos y contenido**, extrayendo los embeddings de clasificación del token [CLS].
- **Sin lematización ni eliminación de las stopwords.**





## 4.6. Modelo Base para Vídeos de YouTube


- Análisis adicional sobre **conjunto de vídeos de YouTube** sobre las temáticas 11s, cambio climático y Covid clasificados como **fake news** y **no fake news**.
- **DistilBERT** como modelo base (distilbert-base-uncased) para la extracción de representaciones semánticas.
- **Sin fine-tuning** del modelo, debido al tamaño del corpus disponible (derivaría en sobreajuste).
- **Los embeddings** extraídos del token [CLS] **capturaron la semántica general** del texto, sin sesgo hacia la tarea de clasificación de fake news.



## 4.7. Validación Estadística

Se aplicó la **prueba U de Mann-Whitney** para validar la significancia estadística de la separación observada en cada uno de los diferentes análisis.

Se calculó el p-valor para ambas dimensiones UMAP de forma independiente, aplicando corrección de Bonferroni para comparaciones múltiples.



## 4.8. Implementación Agéntica

El sistema utiliza un agente inteligente que automatiza el proceso completo:



### 1. Extracción

Scraping web



### 2. Análisis LLM

Basado en el modelo  
**GPT-OSS-120b.**



### 3. Clasificación

Detección binaria:  
**clickbait o no clickbait.**



### 4. Reformulación

Propuesta de títulos  
informativos y neutrales.



Configuración

Medios de comunicación

ABC x HuffPost x

OkDiario x

20minutos x


El Confidencial x

Eldiario x RTVE x


Categorías

Internacional x

Máximo de noticias por categoría y medio



Pausa entre peticiones



JSON de salida por medio:

- ABC: ABC.json
- HuffPost: elhuffpost.json
- OkDiario: okdiario.json
- 20minutos: 20minutos.json
- El Confidencial: elconfidencial.json
- Eldiario: eldiario.json
- RTVE: RTVE.json
- Mediterráneo Digital: mediterraneodigital.json
- La Vanguardia: lavanguardia.json

Títulos sin clickbait:  
titulos\_sin\_clickbait/

Logs por ejecución:  
razonamientos/yyyy-mm-dd-  
HH\_mm.csv

Separador de logs: tabulador

Agente detector de clickbait en noticias

Versión 5.2: scrapea uno o varios medios, clasifica noticias nuevas, guarda cada medio en su JSON, usa cola de pendientes, crea un CSV/TSV por ejecución y genera títulos alternativos sin clickbait para las noticias clickbait.

Ejecutar agente

1. Preparando cola de noticias

Ver resumen de scraping y pendientes

| Medio                | Categoría     | Pendientes usados | Nuevas scrapeadas | Enlaces revisados | Objetivo |
|----------------------|---------------|-------------------|-------------------|-------------------|----------|
| ABC                  | Internacional | 1                 | 0                 | 0                 | 1        |
| HuffPost             | Internacional | 1                 | 0                 | 0                 | 1        |
| OkDiario             | Internacional | 0                 | 1                 | 1                 | 1        |
| 20minutos            | Internacional | 0                 | 1                 | 1                 | 1        |
| El Confidencial      | Internacional | 0                 | 1                 | 1                 | 1        |
| Eldiario             | Internacional | 0                 | 1                 | 1                 | 1        |
| RTVE                 | Internacional | 0                 | 1                 | 1                 | 1        |
| Mediterráneo Digital | Internacional | 0                 | 0                 | 7                 | 1        |
| La Vanguardia        | Internacional | 0                 | 1                 | 1                 | 1        |

Noticias en el lote de clasificación: 8

Noticias pendientes acumuladas ahora mismo: 14

2. Analizando noticias con el agente

- > 1. [ABC | Internacional] La visita de Putin convierte a China en el «centro de la diplomacia mundial»
- > 2. [HuffPost | Internacional] Horror en California: al menos cinco muertos tras un tiroteo en la mayor mezquita de San Diego
- > 3. [OkDiario | Internacional] José Daniel Ferrer (disidente cubano): «Zapatero y Sánchez son cómplices de Cuba y Venezuela»
- > 4. [20minutos | Internacional] Muere un hombre tras ser atacado por un tiburón en Australia, el segundo en 8 días
- > 5. [El Confidencial | Internacional] EEUU e Irán alcanzan un principio de acuerdo para reabrir el estrecho de Ormuz
- > 6. [Eldiario | Internacional] Al menos 14 muertos en ataques israelíes en el sur del Líbano mientras Irán y EEUU se acercan a un acuerdo
- > 7. [RTVE | Internacional] La generación que rompió el silencio en Cuba en redes sociales: "Tengo miedo de no saber cuál será mi último video"

## Configuración

Medios de comunicación

ABC x HuffPost x

OkDiario x

20minutos x

El Confidencial x

ElDiario x RTVE x

Categorías

Internacional x

Máximo de noticias por categoría y medio

1

Pausa entre peticiones

1.00

JSON de salida por medio:

- ABC: ABC.json
- HuffPost: elhuffpost.json
- OkDiario: okdiario.json
- 20minutos: 20minutos.json
- El Confidencial: elconfidencial.json
- ElDiario: eldiario.json
- RTVE: RTVE.json
- Mediterráneo Digital: mediterraneodigital.json
- La Vanguardia: lavanguardia.json

Títulos sin clickbait:  
titulos\_sin\_clickbait/Logs por ejecución:  
razonamientos/yyyy-mm-dd-  
HH\_mm.csv

Separador de logs: tabulador

Noticias pendientes acumuladas ahora mismo: 14

## 2. Analizando noticias con el agente

|                                                                                                                                                                                                                                                           |       |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------|
| 1. [ABC   Internacional] La visita de Putin convierte a China en el «centro de la diplomacia mundial»                                                                                                                                                     |       |
| Etiqueta                                                                                                                                                                                                                                                  | Score |
| Clickbait                                                                                                                                                                                                                                                 | 0.88  |
| Título sin clickbait propuesto: Putin y Xi Jinping se reúnen en Pekín para discutir acuerdos energéticos y comerciales                                                                                                                                    |       |
| Estado títulos sin clickbait: añadida                                                                                                                                                                                                                     |       |
| Archivo títulos sin clickbait: C:\Users\marti\Documents\Codigo-Master-Datos\NLP\ProyectoNLP\ProyectoNLP\agente\titulos_sin_clickbait\ABC.json                                                                                                             |       |
| Estado JSON: añadida                                                                                                                                                                                                                                      |       |
| Archivo JSON: C:\Users\marti\Documents\Codigo-Master-Datos\NLP\ProyectoNLP\ProyectoNLP\agente\data\ABC.json                                                                                                                                               |       |
| Motivo: El titular exagera al afirmar que la visita de Putin convierte a China en el 'centro de la diplomacia mundial', creando una expectativa sensacionalista no respaldada por el contenido que describe una reunión bilateral.                        |       |
| Link: <a href="https://www.abc.es/internacional/putin-prepara-inminente-encuentro-jinping-china-20260518014358-nt.html">https://www.abc.es/internacional/putin-prepara-inminente-encuentro-jinping-china-20260518014358-nt.html</a>                       |       |
| 2. [HuffPost   Internacional] Horror en California: al menos cinco muertos tras un tiroteo en la mayor mezquita de San Diego                                                                                                                              |       |
| Etiqueta                                                                                                                                                                                                                                                  | Score |
| NO Clickbait                                                                                                                                                                                                                                              | 0.94  |
| Estado títulos sin clickbait: no aplica: la noticia no es clickbait                                                                                                                                                                                       |       |
| Archivo títulos sin clickbait: C:\Users\marti\Documents\Codigo-Master-Datos\NLP\ProyectoNLP\ProyectoNLP\agente\titulos_sin_clickbait\elhuffpost.json                                                                                                      |       |
| Estado JSON: añadida                                                                                                                                                                                                                                      |       |
| Archivo JSON: C:\Users\marti\Documents\Codigo-Master-Datos\NLP\ProyectoNLP\ProyectoNLP\agente\data\elhuffpost.json                                                                                                                                        |       |
| Motivo: El titular informa de forma directa y concreta el hecho (tiroteo con al menos cinco muertos en la mayor mezquita de San Diego) sin exageración, suspenso artificial ni discrepancia con el contenido.                                             |       |
| Link: <a href="https://www.huffingtonpost.es/global/horror-california-cinco-muertos-tiroteo-mayor-mezquita-san-diego-f202605.html">https://www.huffingtonpost.es/global/horror-california-cinco-muertos-tiroteo-mayor-mezquita-san-diego-f202605.html</a> |       |
| 3. [OkDiario   Internacional] José Daniel Ferrer (disidente cubano): «Zapatero y Sánchez son cómplices de Cuba y Venezuela»                                                                                                                               |       |
| 4. [20minutos   Internacional] Muere un hombre tras ser atacado por un tiburón en Australia, el segundo en 8 días                                                                                                                                         |       |
| 5. [El Confidencial   Internacional] EEUU e Irán alcanzan un principio de acuerdo para reabrir el estrecho de Ormuz                                                                                                                                       |       |
| 6. [ElDiario   Internacional] Al menos 14 muertos en ataques israelíes en el sur del Líbano mientras Irán y EEUU se acercan a un acuerdo                                                                                                                  |       |
| 7. [RTVE   Internacional] La generación que rompió el silencio en Cuba en redes sociales: "Tengo miedo de no saber cuál será mi último video"                                                                                                             |       |

## 4.8.1 ¿Cómo lo hace?

### 1. Selección y 2. Extracción

- Selección de medios y volumen de noticias.
- Scraping de noticias.
- Generación de JSON en carpeta "**Pendientes**".

### 3. Procesamiento del Agente

- Recupera noticias pendientes.
- Análisis con el modelo **GPT-OSS**

### 4. Validación de Proceso

¿Se puede procesar?

**NO:** Permanece en "Pendientes" para reintento.

**SÍ:** Se elimina de "Pendientes" y se enriquece el JSON.

### 5. Clasificación de Clickbait

**Resultado: NO**

- Se guarda directamente como noticia clasificada.


**Resultado: SÍ**

- Guardado como noticia clasificada.
- **Generación de nuevo título** (JSON adicional) en carpeta "Títulos sin clickbait".


### 6. Registro y Trazabilidad

Exportación CSV en "Razonamientos" de los motivos de clasificación







## **5. Resultados**



## Extracción de Características




Curva ROC




# Fine-Tuning: Taniwa

Espacios Embebidos de Títulos - Análisis UMAP




Espacios Embebidos de Contenido - Análisis UMAP






# Fine-Tuning: Taniwa - Categorías

Espacios Embebidos de Títulos - UMAP




Espacios Embebidos de Contenido - UMAP




# Fine-Tuning: Taniwa - Periódico

## Espacios Embebidos de Títulos por Periódico - Análisis UMAP




## Espacios Embebidos de Contenido por Periódico - Análisis UMAP




# Fine-Tuning: GPT

Espacios Embebidos de Títulos - Análisis UMAP




Espacios Embebidos de Contenido - Análisis UMAP






# Fine-Tuning: GPT - Categorías

Espacios Embebidos de Títulos - UMAP




Espacios Embebidos de Contenido - UMAP




# Fine-Tuning: GPT - Periódico

## Espacios Embebidos de Títulos por Periódico - Análisis UMAP




## Espacios Embebidos de Contenido por Periódico - Análisis UMAP




# Modelo Base: YouTube - Títulos

Espacios Embebidos de Títulos - Análisis UMAP




Espacios Embebidos de Contenido - Análisis UMAP






# Modelo Base: YouTube - Contenidos

Espacios Embebidos de Títulos - UMAP




Espacios Embebidos de Contenido - UMAP




# Fine-Tuning: GPT - Taniwa

Acuerdo BERT vs TANIWA -- Titulos (Kappa=0.437)




Acuerdo BERT vs TANIWA -- Contenido (Kappa=-0.023)




# Fine-Tuning: GPT - Taniwa

Acuerdo BERT vs TANIWA -- Títulos (Kappa=0.437)





Acuerdo BERT vs TANIWA -- Contenido (Kappa=-0.023)



| Métrica        | Títulos | Contenido |
|----------------|---------|-----------|
| Acuerdo simple | 82.0%   | 62.6%     |
| Cohen's Kappa  | 0.437   | -0.023    |



# Fine-Tuning: Análisis de discrepancias en título





# Fine-Tuning: Análisis de discrepancias



Ambos No clickbait


 20minutos EDICIONES 

**Tiroteo en el centro de Atenas: un hombre de 89 años deja cinco heridos y es detenido tras darse a la fuga**

Ambos clickbait

 20minutos EDICIONES 

**El rey Carlos III 'trolea' al presidente Trump en un brindis en la Casa Blanca: "Si no fuera por nosotros, ustedes hablarían francés"**



# Conclusiones

## Análisis Semántico

Las **características lingüísticas tradicionales** son insuficientes para detectar patrones complejos.

Los **embeddings de BERT** permitieron analizar la coherencia semántica entre el título y el contenido de la noticia, permitiendo diferenciar mejor las noticias clickbait de las no clickbait.

## Taniwa vs GPT

**Taniwa:** Se centra principalmente en el titular, y identifica más casos de clickbait en noticias de Cultura.


**GPT:** compara el titular con el contenido de la noticia, y detecta una mayor presencia de clickbait en Internacional.

## Límites y trabajo futuro

El modelo basado en contenido fue menos estable y generó más ruido que el entrenamiento con titulares

El análisis en YouTube resultó inconcluso debido al bajo volumen de datos y la ausencia de fine-tuning.

**Trabajo futuro:** Ampliar el dataset y analizar un fine-tuning por periódico para identificar patrones semánticos específicos.



# **¡Gracias por vuestra atención!**

Enlace al repositorio del proyecto:

<https://github.com/hepejaAED/ProyectoNLP>

